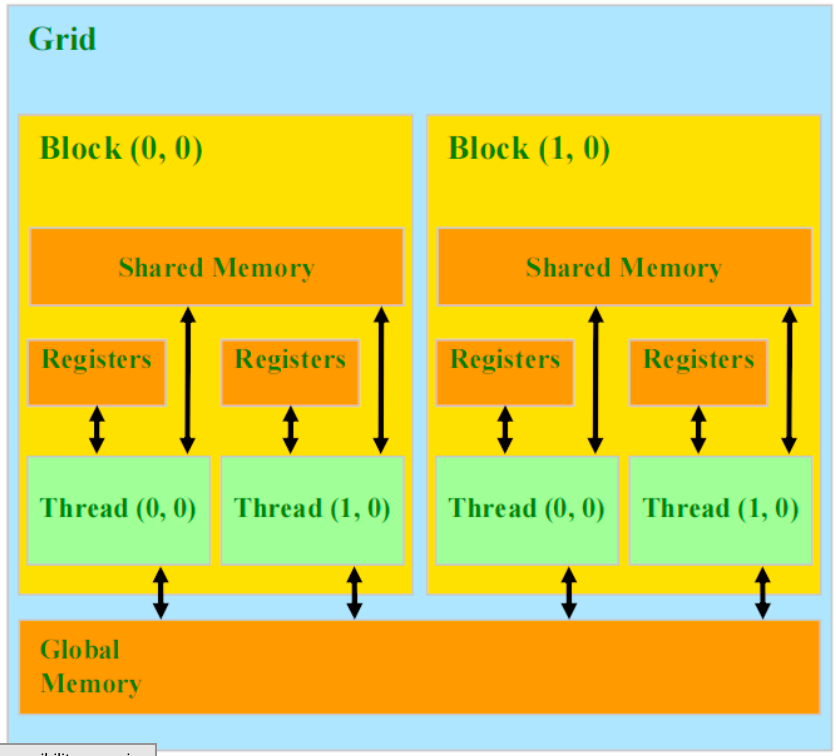
# 实验原理

## CUDA共享显存优化

共享内存（Shared Memory）是一种位于 CUDA 架构中每个流多处理器（Streaming Multiprocessor, SM）内的快速缓存，用于同一线程块内的线程共享数据。相比全局内存，访问共享内存的速度更快，因此在需要频繁访问相同数据时，共享内存能大幅提升性能。通过将多次使用的数据提前加载到共享内存，可有效减少全局内存的访问次数，从而降低延迟、提高带宽利用率。共享内存的加速原理可以概况为以下关键点：

- 快速访问速度：共享内存位于 CUDA 的每个流多处理器上，具有非常低的访问延迟，速度远快于全局显存。这使得它非常适合存储需要频繁访问的数据。
- 线程块内共享：共享内存可以被同一线程块内的所有线程访问和共享，这意味着多个线程可以协同工作，减少重复读取相同的数据，从而节省内存访问的时间。

如图2-1所示，共享内存位于每个线程块内部，允许同一块内的所有线程快速共享数据，访问速度比全局内存快得多。减少了内存的访问次数，降低了延迟，并提高了内存带宽利用率。




Loading [Contrib]/a11y/accessibility-menu.js

图2-1 线程块结构和多层次内存关系的示意图

Loading [Contrib]/a11y/accessibility-menu.js